

Описание

Задачи

Платформенное решение семантического (умного) поиска по содержимому в виде шаблонного сервиса, разворачиваемого и настраиваемого отдельно для каждого прикладного продукта. Со стороны прикладного продукта не требуется глубокого погружения в детали функционала поиска, требуется только управлять потоком данных (добавлять, изменять, удалять) и передавать поисковые запросы.

Концепт решения

В качестве реализации семантического поиска выбран векторный поиск. Он основан на преобразовании документов и поисковых запросов в числовые векторы в n -мерном пространстве, где близость векторов отражает смысловую близость текстов. Поиск сводится не к проверке соответствия запросу, а к ранжированию документов по степени семантической близости к запросу. Поэтому векторный поиск в строгом смысле является всегда ранжированием, а не бинарным поиском «нашлось / не нашлось».

Важно понимать, что система не генерирует готовый ответ на вопрос (это не LLM), а только предоставляет наиболее релевантные данные по мнению выбранной лингвистической модели.

Смысловая близость объектов поиска и поисковой строки определяется близостью векторных представлений. Существует ряд алгоритмов определения векторной близости. На текущий момент мы используем скалярное произведение (более быстрый вариант косинусного расстояния) и используем ML-модель, реализующую векторизацию, возвращающую "плотные" нормализованные векторы.

Декомпозиция

Шаблонный поисковый сервис

Шаблон для разворота сервисов семантического поиска под конечные задачи на базе векторного брокера Elasticsearch версии не ниже 9.2.4 (ранее использовались PostgreSQL + расширение pgvector.rs - устарело).

Решение о создании нового сервиса принимается на основании появления нового прикладного типа данных. Примеры таких данных: статьи базы знаний, интенты, файлы диска и т.п. Мы выбрали схему с разворотом нового сервиса из шаблона под каждую прикладную задачу для лучшей масштабируемости и возможности доработать АПИ для узкой задачи конкретного потребителя. Если доработка может быть полезна во всех использованиях - она выполняется в шаблонном сервисе. Для задач каждого сервиса разворачивается отдельный кластер Elasticsearch.

Вход - поисковая строка.

Выход - набор идентификаторов объектов, отсортированный по убыванию схожимости.

ML Модель ([Подсистема вычисления эмбедингов для текстов](#))

Обеспечивает взаимодействие с выбранной лингвистической моделью с целью получения векторного представления. В нашем случае - это BAAI/bge-m3 и сервис text-embedder.

Вход - входная строка (текст)

Выход - векторное представление

Модель возвращает плотный вектор размерностью 1024 значения.

Схема взаимодействия сервисов, базовых сущностей

