

Stateful SabyDoc парсер

Парсер предназначен для разбора документов в sabydoc-формате.

SabyDoc представляет собой json-документ с тремя полями:

- **name** - название в формате строки,
- **meta** - json произвольного типа. Объект meta содержит дополнительную информацию о документе, например, оглавление.
- **body** - документ [JsonML Richtext](#).

```
1 {  
2  
3   "name": "Техническое задание",  
4  
5   "meta": {"tableOfContents": true},  
6  
7   "body": [[ < jsonml richtext > ]]  
8  
9 }
```

Изображения в SabyDoc закодированы в формате Base64 и расположены внутри документа:

```
"src": "data:image/png;base64,iVBORw0KGgoAAAANSUhEUgAAAzwAAAcAEIAAADK8w0/AA
```

Стандартный [SAX парсер JSON представления текста](#) передает в сторону потребителя информацию о теге через [мост](#), однако при передаче через этот мост изображения в формате Base64, браузер не справляется с загрузкой большого объема данных.

Для устранения проблем с загрузкой изображений в SabyDoc используется механизм трансформации источника изображения из схемы Base64 в файл на файловой системе, который работает следующим образом:


- SabyDoc парсер понимает, что следующий узел, который нужно передать в сторону потребителя, это изображение в Base64 и сохраняет его в кэше на диске,
- В теге img устанавливается ссылка на локальное изображение на диске (uri),
- SabyDoc парсер передает в сторону потребителя тег img с uri изображения, что обеспечивает быстрый разбор документа;
- Просмотрщик строит модель документа, а изображение запрашивает асинхронно по uri во время просмотра.

Реализация данного механизма в C++ описана в разделе ["Работа с изображениями"](#).

Принципиальное устройство

Stateful SabyDoc парсер реализован на базе [SAX парсера JSON представления текста](#).

Принципиальное устройство парсера изображено на рисунке:



Парсинг SabyDoc происходит следующим образом:

1. Потребитель вызывает Sabydoc парсер с помощью метода Parse()/ParseFromFile() для парсинга json-документа,
2. Sabydoc парсер передает json-документ JSON SAX парсеру, который обрабатывает структуру документа,
3. JSON SAX парсер, дойдя до поля **body**, отправляет документ JSON RichText парсеру, для обработки данных в поле **body**,
4. Sabydoc парсер и JSON RichText парсер вызывают обработчик события JsonRTSaxHandler, который реализует методы обработки данных,
5. JsonRTSaxHandler возвращает потребителю элементы обработанного json-документа.

Реализация в C++

Класс:

```
sbis::jsonxml::JsonSabyDocSaxParser
```

Конструктор класса:

```
JsonSabyDocSaxParser( UniquePtr< JsonRTSaxHandler >::type handler );
```

принимает в качестве параметра умный указатель на обработчик событий типа JsonRTSaxHandler.

Работа с изображениями

Конструктор класса с включенным механизмом трансформации источника изображения из схемы Base64 в файл на файловой системе:

```
JsonSabyDocSaxParser( UniquePtr< JsonRTSaxHandler >::type handler, String  
const& uri );
```

Принимает в качестве параметров обработчик событий типа JsonRTSaxHandler и путь до директории на файловой системе в которую будет производиться запись трансформированных изображений.

В теге img будет установлена ссылка на изображение на диске.

```

1 struct SabyDocTransformImgSrcHandler : JsonRTSaxHandler
2 {
3     ...
4 }
5
6 // обработчик событий
7 auto handler = std::make_unique< SabyDocTransformImgSrcHandler >();
8 // парсер
9 auto parser = std::make_unique< JsonSabyDocSaxParser >( std::move(
```

```
    handler ),  
10    L"/tmp/folder_to_save_transformed_images_in" );  
11    parser->ParseFromFile( L"/path_to_saby_doc_file" );
```

Обработчик JsonRTSaxHandler

Методы обработчика JsonRTSaxHandler, которые используются для работы с sabydoc-документами, описаны в [статье](#).